

Relatório técnico — apoio à classificação de câncer de mama

1. Visão geral do projeto

Este projeto apresenta uma solução inicial de Machine Learning para apoiar a classificação de exames em dois grupos:

- **Benigno (B)**: amostra sem indicação de malignidade no rótulo da base;
- **Maligno (M)**: amostra com indicação de malignidade no rótulo da base.

O objetivo não é substituir o diagnóstico médico. O sistema funciona como uma ferramenta de **apoio à triagem**, capaz de fornecer uma estimativa baseada nos dados de entrada. A decisão clínica deve continuar sendo tomada por um profissional de saúde, com base no histórico da paciente, exames, imagens, biópsias e protocolos clínicos.

O fluxo completo está implementado no notebook `notebooks/01_eda.ipynb`, nas seções de EDA e de modelagem.

2. Problema de saúde escolhido

O câncer de mama é um problema relevante para a saúde da mulher, e a detecção precoce pode apoiar decisões de encaminhamento e investigação. Neste projeto, o problema é formulado como uma **classificação binária supervisionada**:

Pergunta	Resposta
O que o modelo recebe?	Medidas numéricas de características de uma massa mamária.
O que o modelo prevê?	Probabilidade de a amostra pertencer à classe maligna.
Quais são as classes?	<code>B</code> (benigno) e <code>M</code> (maligno).
Qual é o principal risco?	Um falso negativo pode atrasar uma investigação necessária.

Os dados utilizados não são imagens de mamografia. Eles são atributos já extraídos de imagens digitalizadas de massas mamárias. Portanto, este projeto não implementa o item extra de Visão Computacional/CNN.

3. Fonte de dados

Foi selecionado o dataset público **Breast Cancer Wisconsin (Diagnostic)**, disponibilizado no Kaggle:

`<https://www.kaggle.com/datasets/uciml/breast-cancer-wisconsin-data/data>`

O arquivo deve ser obtido pela pessoa que executa o projeto e salvo em `data/breast_cancer_data.csv`. Ele não é versionado no repositório para evitar distribuir dados sem necessidade. As instruções de download estão em `data/README.md`.

A base contém uma coluna `diagnosis` e atributos como:

- `radius_mean`: medida média do raio;
- `texture_mean`: medida média de textura;
- `perimeter_mean`: medida média de perímetro;
- `area_mean`: medida média de área;
- atributos de suavidade, compacidade, concavidade, simetria e dimensão

fractal;

- medidas do erro padrão (*_se) e dos valores extremos (*_worst).

Essas variáveis descrevem características morfológicas. Elas não representam o contexto clínico completo de uma paciente.

4. Exploração dos dados (EDA)

A primeira parte do notebook realiza a Análise Exploratória de Dados (EDA) para entender a base antes do treinamento.

4.1 Verificação inicial

São verificados:

1. quantidade de linhas e colunas;
2. tipos de dados;
3. distribuição do diagnóstico;
4. valores ausentes;
5. colunas que não devem ser usadas como preditores.

A coluna `id` é removida porque é apenas um identificador e não possui significado clínico para a previsão. Colunas completamente vazias, como `Unnamed: 32` quando presente no CSV original, também são removidas.

4.2 Distribuição das classes

O notebook apresenta um gráfico com a quantidade de exemplos benignos e malignos. Essa análise é importante porque uma base desbalanceada pode levar um modelo a favorecer a classe mais frequente.

Em saúde, analisar somente a acurácia pode ser enganoso. Por exemplo, um modelo que classifica a maioria dos casos como benignos pode obter uma acurácia aparentemente boa e, ainda assim, deixar de sinalizar casos malignos.

4.3 Análise de correlação

O projeto calcula a correlação de Pearson entre as variáveis numéricas e o desfecho codificado (0 para benigno, 1 para maligno). Também é exibido um mapa de calor com os atributos mais associados ao alvo.

Essa análise ajuda a:

- encontrar atributos potencialmente relevantes;
- identificar variáveis muito parecidas entre si;
- orientar a interpretação dos resultados.

Correlação não demonstra causalidade. Uma variável correlacionada ao diagnóstico não é, isoladamente, a causa da doença.

5. Pré-processamento

O pré-processamento prepara os dados para que os modelos possam utilizá-los de forma consistente e sem vazamento de informação.

5.1 Limpeza e tratamento de ausências

O pipeline trata dados ausentes da seguinte maneira:

- colunas numéricas: imputação pela **mediana**;

- colunas categóricas: imputação pelo valor **mais frequente**.

Embora esta base específica seja predominantemente numérica, o pipeline também suporta dados categóricos. Isso torna o fluxo mais reutilizável caso novas variáveis sejam adicionadas no futuro.

5.2 Conversão e escala

As variáveis numéricas são padronizadas com `StandardScaler`. Esse processo centraliza e escala os valores, o que é particularmente importante para a Regressão Logística, pois as medidas possuem escalas muito diferentes.

Caso existam colunas categóricas, elas são convertidas com `OneHotEncoder`.

5.3 Separação entre treino e teste

Os dados são separados em:

- **80% para treinamento:** utilizados para ajustar os transformadores e os modelos;
- **20% para teste:** reservados para a avaliação final.

A separação é estratificada, preservando aproximadamente a proporção de casos benignos e malignos em ambos os conjuntos. O `Pipeline` do `scikit-learn` garante que imputação, escala e codificação sejam ajustadas somente com dados de treino, evitando vazamento de dados do conjunto de teste.

6. Modelos preditivos

São treinados e comparados dois modelos.

6.1 Regressão Logística

A Regressão Logística é um modelo linear de classificação. Ela é usada como baseline por ser eficiente, interpretável e adequada para prever probabilidades em problemas binários.

6.2 Random Forest

O Random Forest combina várias árvores de decisão. Ele pode capturar relações não lineares entre os atributos e costuma ser robusto para dados tabulares.

Nos dois modelos é utilizado `class_weight="balanced"`, que aumenta a atenção dada à classe menos frequente durante o treinamento.

7. Treinamento e avaliação

Para cada modelo, o notebook calcula as métricas no conjunto de teste:

Métrica	O que mede	Por que importa neste probl
Accuracy	Proporção total de acertos	Resume o desempenho geral,
Recall de malignidade	Casos malignos corretamente identificados entre todos os malignos	É prioritário porque falsos neg
F1-score de malignidade	Equilíbrio entre precisão e recall	Ajuda a avaliar se o ganho de
ROC-AUC	Capacidade de ordenar casos malignos acima de benignos em diferentes limiares	Permite comparar a discrimina

Também são gerados:

- relatório de classificação;
- matriz de confusão;
- curva ROC.

O modelo é selecionado inicialmente pelo maior **recall da classe maligna**, considerando F1-score e ROC-AUC como critérios complementares. Os valores numéricos devem ser obtidos ao executar o notebook com a base de dados; este relatório não apresenta métricas inventadas sem uma execução reproduzível.

8. Explicabilidade

Modelos em saúde precisam ser interpretados com cautela. O notebook inclui duas formas de explicabilidade:

1. **Importância por permutação:** embaralha uma variável por vez e mede a queda de desempenho. Uma queda maior sugere que o modelo dependia mais daquela variável;
2. **SHAP (opcional):** mostra a contribuição de cada atributo para as previsões. É executado quando a biblioteca shap está instalada.

As explicações descrevem o comportamento do modelo, não uma relação causal ou uma justificativa clínica suficiente para diagnóstico.

9. Como realizar uma previsão com novos dados

Depois de executar todas as células do notebook, a função `prever_risco_cancer_mama()` fica disponível.

Para testar exemplos já separados para teste:

```
prever_risco_cancer_mama(X_test.head(1))
```

Para inserir novos dados, crie o arquivo `data/nova_amostra.csv` com as mesmas colunas de atributos da base de treinamento e sem `id`, `diagnosis` ou `Unnamed: 32`. Em seguida, execute:

```
nova_amostra = pd.read_csv("../data/nova_amostra.csv")
nova_amostra = nova_amostra.drop(
    columns=["id", "diagnosis", "Unnamed: 32"],
    errors="ignore",
)

resultado = prever_risco_cancer_mama(nova_amostra)
display(resultado)
```

O resultado contém:

- `probabilidade_malignidade`: estimativa numérica entre 0 e 1;
- `limiar`: valor usado para sinalizar a triagem, inicialmente 0.50;
- `orientacao`: mensagem de encaminhamento para avaliação médica quando o

limiar é atingido;

- `aviso`: lembrete de que o resultado não é um diagnóstico definitivo.

O modelo treinado é salvo localmente em `models/modelo_cancer_mama.joblib`. Esse arquivo é ignorado pelo Git porque é um artefato gerado pela execução e deve ser versionado apenas em uma estratégia controlada de MLOps.

10. Limitações, ética e uso responsável

Esta solução não pode ser usada diretamente em atendimento clínico. Antes de qualquer uso real, seriam necessários:

- validação externa em diferentes hospitais, equipamentos e populações;
- avaliação prospectiva e revisão por especialistas;
- análise de desempenho por subgrupos, como idade, raça/etnia e região;

- definição clínica do limiar de decisão;
- governança, segurança e rastreabilidade dos dados;
- conformidade com a LGPD e demais exigências éticas e regulatórias;
- monitoramento contínuo de qualidade e deriva do modelo.

Além disso, uma probabilidade baixa não exclui câncer e uma probabilidade alta não confirma a doença. O resultado deve sempre ser combinado com a avaliação médica.

11. Como reproduzir o projeto

```
cd tech-challenge-fase1
python3.12 -m venv .venv
source .venv/bin/activate # Linux/macOS
pip install -r requirements.txt
```

Depois:

1. baixe data.csv conforme data/README.md;
2. coloque-o em data/breast_cancer_data.csv;
3. abra notebooks/01_eda.ipynb;
4. execute as células de cima para baixo.

12. Conclusão

O projeto atende à proposta de criar uma solução inicial de IA para classificação de risco/diagnóstico de câncer de mama com dados estruturados. O notebook cobre exploração, limpeza, correlação, pré-processamento, treinamento, comparação de modelos, avaliação, explicabilidade e uma função de inferência.

O principal resultado do projeto é demonstrar um fluxo técnico reproduzível de Machine Learning. A aplicação prática em saúde, contudo, depende de validação clínica e de supervisão humana rigorosa.